

ВЕБ-ПРИЛОЖЕНИЕ НА ОСНОВЕ RAG ДЛЯ РАБОТЫ С ДОКУМЕНТАЦИЕЙ POSTGRESQL С УЧЁТОМ ВЕРСИИ

Студент:
Жатиков Артур Русланович,
группа 221-3210
Научный руководитель:
Гонтовой Сергей Викторович, к.т.н.

- Официальная документация PostgreSQL обширна и публикуется по отдельным основным версиям.
- Пользователь обычно формулирует запрос как практическую задачу, а не как точное название раздела.
- Обычный поиск возвращает список страниц, но не формирует связный проверяемый ответ.
- Языковая модель без привязки к источникам может смешивать сведения разных версий.
- Для инженерного применения нужен ответ с источниками и контролем выбранной версии PostgreSQL.

Цели и задачи работы

Цель: разработать веб-приложение, которое по запросу пользователя, версии PostgreSQL и режиму ответа извлекает релевантные фрагменты корпуса, проверяет подтверждения и формирует результат с источниками.

- проанализировать предметную область и структуру документации PostgreSQL;
- исследовать влияние версии СУБД на корректность ответа;
- сформулировать функциональные и нефункциональные требования;
- спроектировать RAG-архитектуру и модель данных;
- разработать алгоритмы индексации, поиска и формирования ответа;
- реализовать интерфейс и программный прототип;
- провести тестирование и оценку работы системы.

Задача 1. Анализ предметной области

- Рассмотрена структура документации PostgreSQL: SQL-команды, администрирование, параметры сервера, репликация, расширения и примечания к выпускам.
- Определены пользователи системы: разработчики, администраторы баз данных, инженеры сопровождения и начинающие специалисты.
- Выявлена проблема: без учета версии в ответ могут попасть сведения из разных веток документации.
- Сформулирован вывод: результат должен быть проверяемым по источникам выбранной версии PostgreSQL.

Задача 2. Анализ подходов и требований


- Сравнены поиск по сайту, полнотекстовый поиск, семантический поиск и RAG-подход.
- Обычный поиск требует ручного анализа страниц; генерация без источников не обеспечивает проверяемость.
- Функциональные требования: версии PostgreSQL 16, 17 и 18, три режима ответа, источники и история запросов.
- Нефункциональные требования: трассируемость, версионная изоляция, контролируемость генерации и тестируемость.

Задача 3. Средства разработки


- Серверная часть: Python 3.12, FastAPI, Pydantic, SQLAlchemy и Alembic.
- Хранение данных: PostgreSQL с расширением pgvector для векторных представлений фрагментов.
- Подготовка корпуса: Beautiful Soup, локальные HTML-страницы официальной документации и Markdown-материалы.
- RAG-компоненты: модель BAAI/bge-m3 для векторных представлений и внешний API языковой модели Groq.
- Интерфейс и проверка: HTML, CSS, JavaScript, Docker Compose и pytest.

Задача 4. Архитектура веб-приложения

- Пользовательский интерфейс, FastAPI и PostgreSQL + pgvector разделены на самостоятельные компоненты.
- Офлайн-контур наполняет базу документами, фрагментами и векторными представлениями.
- RAG-контур связан с подготовленным корпусом, источниками и внешним API языковой модели Groq.



Задача 5. Модель хранения данных



Ключевые связи

- versions -> documents
- documents -> chunks -> векторные представления
- query_history -> query_sources -> chunks
- источники ответа связаны с фрагментами

Задача 6. Индексация и обработка запроса

- Индексация: загрузка корпуса, очистка, разбиение на фрагменты, расчет векторных представлений и запись в PostgreSQL.
- Поиск объединяет семантическую ветку pgvector и лексический сигнал по техническим терминам запроса.
- Контроль версии выполняется фильтрацией по основной версии и проверкой URL вида /docs/<version>/.
- После повторного ранжирования система проверяет достаточность официальных подтверждений перед генерацией.

Задачи 7–8. Интерфейс и прототип

The screenshot shows the PostgreSQL RAG Assistant web interface. At the top, it says 'Помощник по документации PostgreSQL' and 'PostgreSQL RAG Assistant'. There is a 'История' button in the top right. The main section is titled 'Задайте вопрос' and includes a prompt to 'Выберите версию и формат ответа, затем получите ответ с источниками.' Below this is a text input field for the question, with an example: 'Например: Как найти активные запросы дольше 5 минут через pg_stat_activity?'. There are two dropdown menus: 'Версия PostgreSQL' (set to PostgreSQL 18) and 'Формат ответа' (with options: Краткий, Подробный, Обучающий). A 'Получить ответ' button is below these. The 'Ответ' section shows 'Пока нет ответа' and a prompt to 'Задайте вопрос и нажмите «Получить ответ».' The 'Источники' section at the bottom says 'Источники появятся после ответа.' On the right side, there are two panels. The 'Примеры вопросов' panel lists several example questions like 'Как найти активные запросы дольше 5 минут?' and 'Объясни EXPLAIN ANALYZE простыми словами.' The 'Недавние запросы' panel, titled 'Открыть историю', shows a list of recent queries with their formats and versions, such as 'Для чего нужна команда CREATE SUBSCRIPTION?' and 'Покажи пошагово, как добавить новую таблицу в уже существующую logical...'

Основные зоны интерфейса

- ввод вопроса;
- выбор версии PostgreSQL;
- выбор режима ответа;
- блок ответа;
- список источников;
- история запросов.

Задача 9. Тестирование

Проверка	Что проверялось
Маршруты API	/api/ask, /api/versions, /api/history, /api/health, /api/admin/reindex
Параметры	валидация версии PostgreSQL и режима ответа
RAG-контур	поиск, повторное ранжирование, контроль версии источников
Безопасность ответа	безопасный отказ при недостатке подтверждений
Данные и интерфейс	история запросов и пользовательский интерфейс

Результат pytest
91 passed
3 skipped

Заключение

Реализовано

- веб-приложение;
- поддержка PostgreSQL 16, 17 и 18;
- три режима ответа;
- источники и история запросов.

Проверено

- API, версия и режимы ответа;
- RAG-контур;
- контроль источников;
- интерфейс и история.

Ограничения

- полнота локального корпуса;
- доступность внешнего API языковой модели Groq;
- нет численных метрик качества ранжирования.

**ВЕБ-ПРИЛОЖЕНИЕ НА ОСНОВЕ RAG ДЛЯ РАБОТЫ
С ДОКУМЕНТАЦИЕЙ POSTGRESQL С УЧЁТОМ ВЕРСИИ**

Студент:
Жатиков Артур Русланович,
группа 221-3210
Научный руководитель:
Гонтовой Сергей Викторович, к.т.н.